

고급 인공지능

- LLM의 기초와 패러다임의 변화

동양미래대학교

컴퓨터소프트웨어공학과

송원문

mooniesong@gmail.com

강의 개요

■ 주제

- LLM의 기초와 패러다임의 변화

■ 내용

- 언어 모델의 원리, LLM vs SLM, GAI의 정의
- 교재 1.1~1.2

■ 학습 목표

- 언어 모델의 확률적 생성 원리를 설명할 수 있다.
- LLM, sLLM, GAI의 차이점과 최신 트렌드를 파악한다.

목차

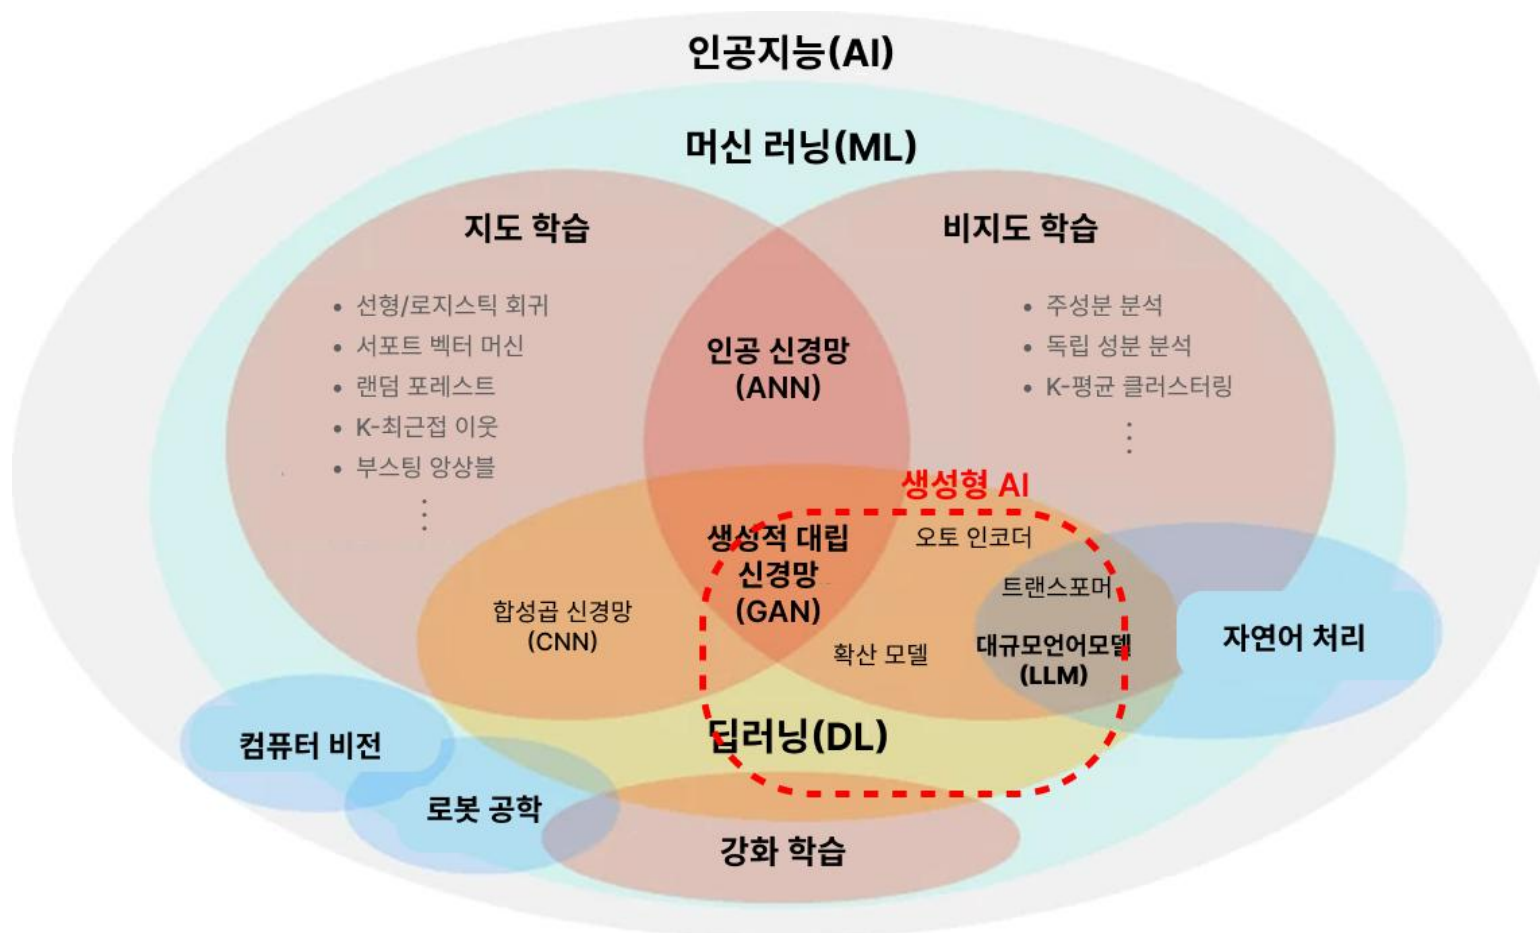
■ LLM 개념

■ LLM 특징과 종류

LLM 개념

■ LLM

- Large Language Model; 대규모 언어 모델
- 인간의 언어를 처리하는 컴퓨터 알고리즘



■ LLM




BY ANTHROPIC



■ 언어 모델 (Language Model)

- 컴퓨터가 어떻게 말을 하고 글을 쓰는지에 대해 정의하는 알고리즘/구조

History of Large Language Models



■ 통계적 언어 모델

- 컴퓨터가 문장이나 단어를 얼마나 자연스럽게 표현할 것인지를 수학/통계적으로 계산하는 방법
- “나는 오늘 점심에” 뒤에 올 문장은? “피자를 먹었다”
- 과거의 데이터에서, 해당 형태의 예시가 많이 존재 했기 때문

■ N-gram



- 일련의 단어나 문자들이 얼마나 자주 함께 나타나는지를 살펴 볼 때 길이를 고려하는 방법
- 단어를 예측할 때, 앞의 $n-1$ 개의 단어를 고려하여 결정
- 가능한 모든 경우의 n -gram을 데이터베이스에 저장하고 있어야 하고, n 이 커지면 문맥을 유연하게 이해하지 못할 수 있음



	i	want	to	eat	chinese	food	lunch	spend
i	5	827	0	9	0	0	0	2
want	2	0	608	1	6	6	5	1
to	2	0	4	686	2	0	6	211
eat	0	0	2	0	16	2	42	0
chinese	1	0	0	0	0	82	1	0
food	15	0	15	0	1	4	0	0
lunch	2	0	0	0	0	1	0	0
spend	1	0	1	0	0	0	0	0




■ 신경망 기반의 언어 모델

- 신경망 – 인간의 뇌에 있는 신경세포(뉴런)가 서로 연결되어 정보를 처리하는 방식을 본 따서 만든 기계 학습 알고리즘
- 신경망 알고리즘을 이용하여 문장이나 단어의 표현을 구조적으로 모델링 (학습)



■ 신경망 기반의 언어 모델 – RNN (Recurrent Neural Network)


- 과거의 정보를 현재의 결정에 반영하는 구조



일 대 다(one-to-many) 다 대 일(many-to-one) 다 대 다(many-to-many)



■ 신경망 기반의 언어 모델 – LSTM (Long Shot Term Memory)

- RNN은 관련 정보와 그 정보를 사용하는 지점 사이 거리가 멀 경우, 학습을 위한 정보의 역전파가 잘 전달되지 않음
- vanishing gradient problem



<관련 정보와 그 정보를 사용하는 지점 사이 거리가 멀 경우 RNN 학습능력 저하>

■ 신경망 기반의 언어 모델 – LSTM (Long Shot Term Memory)



- **Cell state:** 장기 기억 (Long-term memory)를 담당. 시퀀스의 정보를 장기적으로 누적하여 전달
Forget gate에서 저장된 장기 정보의 일부는 지워지고, input gate에서 현재 정보의 일부가 새롭게 누적되어 기억
- **Hidden state:** 단기 기억 (Short-term memory)를 담당. 시퀀스의 단기적인 상태를 요약
현재 시점의 output으로 사용되면서 다음 시점의 연산에 필요한 단기적 정보로써 전달

■ 트랜스포머

- “문장 속 단어들이 서로 어떤 관계를 맺고 있는지 스스로 파악하여 맥락을 이해하는 기술”
- 2017년 구글에서 제안, 언어 모델의 판도 변환
- 이전의 언어 모델들이 단어나 구절 단위로 이해/처리하는 관점이었다면, 트랜스포머는 문장과 단락 전체에 대한 관점에서 접근
- 이를 통해 의도를 심층적으로, 맥락을 고려하여 이해할 수 있게 되면서 활용 범위가 넓어짐 (콘텐츠 생성, 문장 요약 등)
- LSTM
 - 책을 한 글자씩 읽으며 내용을 기억하려고 애쓰는 방식, 느리고 앞 내용을 잊기 쉬움
 - 정보를 누적(Cell State)해서 전달
- Transformer
 - 문장 전체를 한눈에 내려다보고 중요한 단어들끼리 선을 연결하는 방식, 빠르고 정확함
 - 어텐션 기법을 이용, 문장 전체의 (단어들간의) 관계도를 그려서 학습

■ 트랜스포머

- GPT (Generative Pretrained Transformer)
 - 주어진 단어들의 다음에 나오는 단어들을 찾아내는 방식의 언어 모델
 - 먼저 대량의 텍스트 데이터를 이용해 언어 모델을 사전 학습(pre-training)하고, 그 다음 특정 태스크에 대해 미세 조정 (fine-tuning) 진행
 - 텍스트 생성에 특화된 모델로 대화, 글쓰기 등의 태스크에 특화
- BERT (Bidirectional Encoder Representations from Transformers)
 - 텍스트를 양방향으로 분석하여 맥락을 이해 하는 언어 모델, 즉 단어의 앞/뒤 문맥을 모두 고려하여 의미를 해석
 - 맥락 중심 이해에 특화된 모델로 요약, 번역과 같은 태스크에 특화

GPT

어제 카페 갔었어 거기 사람 많더라



BERT

어제 카페 갔었어 사람 많더라



■ LLM; Large Language Model; 거대 언어 모델

- 대규모의 데이터로 훈련된 매우 큰 규모의 인공지능 기반 언어 모델

■ [데이터] OpenAI는 GPT-3 모델을 학습시킬 때 약 45TB의 텍스트 데이터를 이용

- 보통 소설책 1권의 텍스트는 약 1MB → 약 4,500만권 → 미국 의회 도서관 내 전체 도서(3,800만권)보다 많은 양
- HD 고화질 영상 1편은 보통 5GB → 약 9,000편 → 1편당 2시간으로 계산하면, 18,000시간 → 약 2년 (24시간*365)
- 고화질 사진은 평균 3MB → 약 1,500만장 → 하루에 사진 10개를 인스타그램에 게시한다면, 약 4,100년

■ [모델의 크기] OpenAI의 GPT-3는 약 1,750억개의 파라미터로 구성

- 파라미터: 모델의 세부 요소를 연결하는 정보들, 각 요소들이 작동하는 세부적인 수학적 정보들을 포함하는 변수의 규모
- 파라미터의 규모가 곧 모델의 성능을 대변하기도 함. 모델이 발전할수록 파라미터의 수는 기하 급수적으로 증가 (GPT-2는 15억개)

■ 주요 LLM 모델들과 파라미터 개수

모델명	개발사	출시	파라미터 개수 (추정치)	특징
GPT-3	OpenAI	2020.6	1,750억 개 (175B)	LLM 열풍의 시작점
GPT-3.5 (ChatGPT)	OpenAI	2022.11	1,750억 개 (175B)	대중화 시대를 연 상징적인 모델
GPT-4	OpenAI	2023.3	약 1.8조 개 (1.8T)	MoE(전문가 혼합) 구조의 선두주자
Gemini 1.5 Flash	Google	2024.2	비공개 (수백억 단위 추정)	속도와 효율성에 최적화된 경량화 모델
Gemini 1.5 Pro	Google	2024.5	약 1.5조 개 ~ 1.8조 개	업계 최대 수준의 컨텍스트 창(2M+ 토큰) 지원
Gemma 2	Google	2024.6	270억 개 (27B)	구글의 기술력을 응축한 강력한 소형 모델(SLM)
Llama 3.1	Meta	2024.7	4,050억 개 (405B)	가장 강력한 성능을 가진 오픈소스 모델
Claude 3.5 Sonnet	Anthropic	2024.6	비공개 (수천억 단위 추정)	코딩 및 논리적 추론 특화
HyperCLOVA X	Naver	2023.8	2,040억 개 (204B)	한국어 및 국내 문화 맥락에 가장 최적화
Solar Pro 3	Upstage	2026.1	1,020억 개(102B)	Mixture-of-Experts (MoE) 방식 채택

목차

■ LLM 개념

■ LLM 특징과 종류

LLM 특징과 종류

■ LLM의 주요 특징

- 인터넷의 텍스트, 책, 논문, 기사 등 다양하고 방대한 양의 텍스트 데이터로부터 학습
- 언어를 이해하고, 생성하는 데 특화
 - 텍스트를 읽고 이해, 자연스러운 언어로 질문에 답변, 글을 작성, 대화
- 특정 작업을 위해 파인 튜닝할 수 있음
 - 파인 튜닝: 특정 목적으로 기존의 모델을 추가 학습 시키는 과정
- 훈련 및 운영을 위한 상당한 규모의 컴퓨팅 자원 필요
 - CPU로는 한계
 - Neural Networks의 병렬처리에 유용한 GPU, TPU
 - 데이터 및 학습 기억 처리를 위한 고속 메모리 (HBM)




■ 주요 LLM

모델명	개발사	모델 크기 (파라미터)	주요 특징
GPT-4o	OpenAI	약 1.8조 개 (추정)	네이티브 멀티모달: 텍스트, 오디오, 이미지를 실시간으로 동시에 처리하며 인간 수준의 대화 속도와 감정을 표현합니다.
Gemini 2.5 Pro	Google	약 1.5조 ~ 2조 개 (추정)	초거대 컨텍스트: 최대 200만 토큰을 한 번에 입력받아 방대한 문서나 장시간의 영상을 한 번에 분석할 수 있는 독보적인 능력을 갖췄습니다.
Claude 3.5 Sonnet	Anthropic	비공개 (수천억 단위)	논리적 추론 및 코딩 특화: 지시 이행 능력이 매우 정교하며, 특히 코딩과 복잡한 기술 문서 작성에서 사용자 만족도가 가장 높습니다.
Llama 3.1 (405B)	Meta	4,050억 개 (405B)	최강의 오픈소스 모델: 폐쇄형 유료 모델들과 대등한 성능을 내는 가장 거대한 오픈소스 모델로, 기업들이 자체 인프라에 구축하기에 최적입니다.
Solar Pro 3	Upstage	1,026억 개 (102B)	한국어 최적화 및 고효율: 한국어 맥락 이해에 특화되어 있으며, 실제 연산 시 필요한 전문가만 활성화하는 MoE 구조로 속도와 정확도를 모두 잡았습니다.

LLM 특징과 종류

■ 멀티모달모델



LLM 특징과 종류

■ 멀티모달모델 (텍스트+이미지)

LLM에 대해 강의하는 이미지를 생성해줘

이미지 생성됨 • LLM 강의: 대규모 언어 모델



LLM 특징과 종류

■ 멀티모달모델 (이미지+텍스트+동영상)

이미지를 동영상으로 변환

시작 이미지

이미지 간

참조 이미지



강사만 춤을 추는 동영상

품질 V2.5

512P

10초

생성 20

전체

동영상

이미지

음악

연설

이미지를 동영상으로 | 02-15 16:47



강사만 춤을 추는 동영상




재프롬프트

재생성



■ LLM vs. GAI (Generative AI; Gen AI)

- LLM: 텍스트를 기반으로 질문에 답을 하거나 글을 작성하고, 대화를 진행하는 등 다양한 언어 작업을 하는데 사용
- GAI: 입력 데이터를 기반으로 새로운 콘텐츠를 생성하는 인공지능
- GAI는 LLM을 포함하는 좀 더 상위 개념
 - 모든 GAI가 LLM을 기반으로 하지는 않지만, LLM은 텍스트 생성에 특정되는 GAI의 한 형태



■ LLM vs. GAI (Generative AI; Gen AI)

구분	GAI	LLM
콘텐츠 생성 범위	텍스트, 이미지, 음성, 코드 등 다양	텍스트에 국한
학습	대규모 데이터에 의존하면서도 이미지, 오디오 등 다양한 데이터 유형을 학습	인터넷, 서적 및 기타 광범위한 텍스트 학습
출력	음악에서 시각적 예술 작품에 이르기까지 광범위한 출력을 생성	사용자의 질문 (프롬프트, prompt)에 일관되고 상황에 맞게 텍스트를 생성 (답변, 컴플리션, completion)
모델	이미지 생성을 위한 GAN 또는 음악과 같은 순차적 데이터를 위한 RNN을 포함한 다양한 형태의 모델 사용	텍스트와 같은 순차 데이터에 효과적인 RNN, 트랜스포머 등 사용
활용 분야	하나의 분야에 국한되지 않고 여러 창의적 분야에 사용 가능	언어 관련 작업에 특화

■ LLM vs. SLM

- SLM; Small Language Model
- 모델의 크기, 학습 데이터의 양, 처리 능력 등이 LLM에 비해 적은 언어 모델
- LLM에 비해 단순하거나 특정한, 제한적인 용도에 적합
- 최근에는, 일반적인 LLM에 비해 적은 규모의 SLM으로 LLM의 성능에 나가는 모델들도 출현 – “모델은 가볍게, 성능은 뛰어나게”

구분	SLM	LLM
모델 크기	수천만~수백만개 이하의 파라미터	수천만~수천억개 이상의 파라미터
컴퓨팅	모바일 및 일반 PC 등 장치에서도 활용	클라우드 또는 수백개의 GPU 환경에서 사용
성능	단순 작업만 동작	복잡한 작업 처리 가능
배포	쉬운 배포/관리	배포를 위한 인프라 필요 (클라우드 등)
학습	수일~수십일 이내 학습 가능	수개월 이상의 학습 필요