

고급 인공지능

- LLM 생성 프로세스와 활용 전략

동양미래대학교

컴퓨터소프트웨어공학과

송원문

mooniesong@gmail.com

강의 개요

■ 주제

- LLM 생성 프로세스와 활용 전략

■ 내용

- 사전 학습, 파인튜닝 및 추가 고려 사항
- 교재 1.3~2.1.1

■ 학습 목표

- 사전 학습부터 모델 생성 전 과정을 이해한다.
- 파인튜닝의 필요성과 적합한 활용 시나리오를 구분한다.

목차


- LLM 생성 과정
- LLM 생성 후 추가 고려 사항
- LLM 활용 방법
 - 파인 튜닝

LLM 생성 과정

■ LLM의 생성 과정

- ① 데이터 수집 및 준비
- ② 모델 설계
- ③ 모델 학습
- ④ 평가 및 검증
- ⑤ 배포 및 유지 보수


■ 기계학습 모델을 만들고 이용하는 프로세스




① 데이터 수집 및 준비

- 언어 모델을 학습시키기 위한 첫 단계

- 모델이 학습을 할 수 있는 형태로 데이터를 모으고 가공하는 일련의 작업을 하는 단계




① 데이터 수집 및 준비



■ 데이터 수집

- 모델이 언어를 이해하고 생성하는 방법을 학습하려면 다양하고 많은 데이터가 필요
- 데이터 식별
 - 언어 모델이 다양한 언어 패턴을 학습할 수 있도록 다양한 주제와 장르, 스타일의 텍스트가 포함되어야 함
- 데이터 수집
 - 식별된 데이터를 실제로 수집
 - HTML 등 웹 문서, PDF/Word 문서, 텍스트 파일, 데이터베이스 등
 - 데이터 수집시에는 저작권, 개인정보 보호 등 법적인 문제를 반드시 고려해야 함


① 데이터 수집 및 준비



■ 데이터 정제

- 데이터의 품질을 결정하는 핵심적인 과정
- 데이터의 품질이 좋아야, LLM의 학습 품질이 좋아지고, 결과의 품질(신뢰성)이 좋아짐
- 학습한 것을 토대로 결과를 산출하므로, 잘못된 데이터로 학습한다면, 잘못된 결과가 나올 가능성이 커짐
- 중복 제거
 - 수집된 데이터에서 중복된 내용을 제거할 필요가 있을 수 있음. 중복된 내용이 들어간다면, 학습에 반영되는 비율이 커질 것
- 노이즈 제거
 - 학습과 무관하다고 판단되는 정보의 제거. 오타자, 잘못된 문장부로, 비정상적인 문자 등에 대한 정리


① 데이터 수집 및 준비



■ 데이터 전처리

- 데이터를 LLM의 학습에 적합한 형태로 만드는 과정, 모델에 입력될 데이터
- 전처리된 데이터는 모델에 입력되는 최종 형태의 데이터이므로, 전처리 과정은 모델 성능에 매우 중요한 과정
- 토큰화 (Tokenization)
 - 긴 텍스트를 작은 단위로 나누는 과정. 영어의 경우 공백, 단어 등 기준으로 분리, 한글의 경우 품사 기준으로 분리 등
- 정규화
 - 대/소문자 통일, 어간(단어의 원형) 추출 등

① 데이터 수집 및 준비



■ 데이터 형식 변경

- 데이터의 형식을 일치시키는 과정
- 예) 'YYMMDD', 'YY/MM/DD' 등의 날짜 데이터는 'YYYY-MM-DD' 형태로 변경
- 데이터의 형식을 일관된 형태로 변경하면, 정보를 찾거나 비교할 때 쉽게 할 수 있음

② 모델 설계

- 학습의 토대가 되는 모델(주로 신경망)의 아키텍처(구조)를 만들어내는 것
- 어떤 모델로 학습할 것인가? 주로 트랜스포머 기반의 모델을 사용
- 하이퍼파라미터를 어떻게 할 것인가? 신경망 구조의 계층 수, 학습률, 배치 크기 등
 - 학습 과정을 제어 할 때 사용하는 모델의 설정 값
 - 값의 설정에는 정답은 없음. 실험과 경험을 통해서 적절한 값으로 설정

③ 모델 학습

- 수집/준비된 데이터와 설계된 모델을 이용해 학습 – “모델링”
- 모델이 데이터로부터 목표에(출력) 도달 가능한 입력 데이터의 패턴을 학습
- 이를 통해 텍스트를 생성하거나 번역을 하는 등의 작업을 수행할 수 있도록 모델을 만들어 내는 과정
 - 고양이과 개에 대한 사진들 속에서,
 - 개와 고양이 각각에 대해 공통된 특징/패턴을 찾아냄
 - 귀, 눈, 입의 모양, 사진에서의 배치 구조 등




④ 평가 및 검증

■ 모델이 얼마나 잘 작동하는가에 대한 평가, 실제로 서비스 했을 때 어느 정도의 성능을 낼 수 있는가에 대한 확인 등

- 성능(답변에 대한 정확도, 답변 제공 속도 등)이 떨어진다면, 데이터를 보완하거나, 모델의 구조/하이퍼파라미터를 변경하여 재 학습 필요

■ 모델의 평가를 위해서도 데이터가 필요.

- 수집된 데이터를 학습(훈련), 검증, 테스트 등의 용도로 나눠서 사용
- 데이터 구分的 필요성
→ 공부는 정확하게 했는가? vs. 시험도 잘 보는가?



■ 모델에 대한 평가 지표

- 정확도 (Accuracy) – 모델이 맞춰야 할 값들에 대해 전체적으로 잘 맞추는가?, 종합 지표
- 정밀도 (Precision) – 특정 값을 기준으로 모델의 결과가 얼마나 잘 맞았는가? 확실한 것을 찾아내는 것이 필요한 경우, 안면 인식
- 재현율 (Recall) – 특정 값을 기준으로, 모델이 원래의 값을 잘 맞췄는가? 잘 찾아 내는 것이 필요한 경우 (놓치면 위험), 암 진단
- F1 점수 (F1 Score) – 정밀도와 재현율을 함께 고려 했을 때 얼마나 좋은가?, 특정 값에 대한 정밀도와 재현율의 조화평균

④ 평가 및 검증

■ 혼동 행렬 (Confusion Matrix)과 평가 지표

		예측 (모델 출력)		계
		개	고양이	
실제	개	118 (정답)	47 (오답)	165 – 실제 ‘개’인 경우
	고양이	15 (오답)	98 (정답)	113 – 실제 ‘고양이’인 경우
계		133 – ‘개’라고 예측한 경우	145 – ‘고양이’라고 예측한 경우	278


- $Accuracy = \text{정답} \div \text{전체} = (118+98) \div 278 = 0.78$
- $Precision\ (개) = \text{정답} \div \text{‘개’라고 예측한 경우} = 118 \div 133 = 0.89$
- $Recall\ (개) = \text{정답} \div \text{실제 ‘개’인 경우} = 118 \div 165 = 0.72$
- $F1\ Score\ (개) = (2 \times Precision \times Recall) \div (Precision + Recall) = 0.79$

⑤ 배포 및 유지 보수

- LLM을 사용자가 사용할 수 있도록 하는 서비스 하는 단계. 서비스에 문제가 있으면 수정/보완하는 작업도 포함
- 학습된 LLM을 배포 할수도 있고, 학습된 LLM 기반으로 챗봇과 같은 응용 프로그램을 만들어서 배포 할 수도 있음


■ 모델 개발 라이프사이클

- 기계학습 모델 개발에 대한 일반적인 라이프사이클



■ 모델 개발 라이프사이클

- MLOps (Machine Learning Development Operations)



목차

- LLM 생성 과정
- LLM 생성 후 추가 고려 사항
- LLM 활용 방법
 - 파인 튜닝

■ 추가적인 고려 사항 – 1) 윤리적 고려 및 보정

- 모델이 생성한 결과의 공정성, 편향성, 투명성을 다루는 데 매우 중요한 과정
- 모델이 다양한 사용자와 상황에 미치는 잠재적인 영향을 신중하게 평가하고 부정적인 결과를 최소화하기 위해 필요



2015년 어느 날 소프트웨어 개발자 재키 앨신(Jacky Alciné)은 자신의 구글 포토 앱을 열어보다가 충격적인 장면을 목격했다. 구글이 새롭게 출시한 이 서비스는 딥러닝 기술을 활용해 사진을 자동으로 분석하고 주제별로 분류하는 기능을 갖추고 있었는데, 그는 '고릴라'라는 폴더를 발견했다.

무심코 그 폴더를 열어본 앨신은 경악할 수밖에 없었다. 그 안에는 1년 전 콘서트에서 촬영한 아프리카계 미국인 친구의 사진이 들어 있었다. 구글의 이미지 인식 신경망이 흑인의 얼굴을 고릴라로 분류해버린 것이었다. 앨신은 곧바로 이 화면을 스크린샷으로 찍어 소셜 미디어에 올리며 "구글 포토, 엉망진창이네. 내 친구는 고릴라가 아니야"라고 적었다.

구글은 즉각 사과하고 재발 방지를 약속했지만, 근본적인 해결책은 제시하지 못했다. 결국 구글이 취한 조치는 포토 서비스에서 아예 '고릴라'라는 분류를 차단하는 것이었다. 문제의 원인은 신경망 훈련에 사용된 데이터에 있었는데, 개발자들은 이런 부작용을 전혀 예측하지 못했다. 구글의 고릴라 분류 사건은 AI 기술의 편향성 문제가 수면 위로 드러난 초기 사례였지만, 이는 빙산의 일각에 불과했다.

LLM 생성 후 추가 고려 사항

■ 추가적인 고려 사항 – 1) 윤리적 고려 및 보정

- 책임감 있는 AI 원칙

공정성	• 성별, 인종, 나이 등에 따른 편향 없이 모든 사용자에게 공정하게 서비스를 제공해야 함
신뢰성 & 안전성	• 사용자에게 안전하며 예측 가능한 위험을 관리하고 예방해야 함
프라이버시	• 사용자의 개인정보를 보호하고 데이터 보안을 유지해야 함
포용성 & 다양성	• 모든 사람이 차별없이 참여하고 혜택을 받을 수 있도록 환경을 조성해야 함
윤리적 사용	• 사회적, 도덕적 기준에 부합하는 방식으로 사용되어야 하며 인간의 존엄성을 존중해야 함
투명성	• AI의 의사 결정 과정이 명확하고 이해 가능해야 하며, 사용자는 AI의 작동 방식과 결정 기준을 알 권리가 있음
책임성	• AI의 결정에 대한 책임을 명확히 하여, 문제 발생시 적절한 해결책을 제시할 수 있어야 함

- 이러한 원칙은, 급속한 기술 발전에 따른 사회적 우려를 해소하고, AI가 사회에 긍정적인 영향을 미치는데 기여하기 위한 가이드라인을 제공하는 역할

LLM 생성 후 추가 고려 사항

■ 추가적인 고려 사항 – 1) 윤리적 고려 및 보정

- LG의 AI 윤리 원칙 사례



LLM 생성 후 추가 고려 사항

■ 추가적인 고려 사항 – 2) 지속적인 모니터링

- LLM은 매우 강력한 언어 모델
- 악의적 사용을 막기 위해서는, 지속적으로 사용자들의 질문과 AI의 답변을 모니터링 해야 함
- 이를 위해, 사람이 질문과 답변을 지속적으로 감시하되, AI가 스스로 악의적 문구를 탐지하도록 하는 방법도 함께 사용할 수 있음

목차

- LLM 생성 과정
- LLM 생성 후 추가 고려 사항
- LLM 활용 방법
 - 파인 튜닝


■ 사용자들이 LLM 서비스를 이용하는 방법은 두 가지

- 추가적인 기능을 구현해 놓은 어플리케이션 서비스를 그대로 이용하는 방법 (예. ChatGPT, Gemini 등 웹 서비스 페이지)
- LLM을 모델에 대한 API를 이용하여 필요한 어플리케이션 서비스를 만드는 방법
 - API (Application Program Interface): 어플리케이션들이 서로 상호 작용하는 방법을 정의하는 일련의 규칙이자 도구
 - 개발자들은 API를 통해 해당 기능을 이용할 수 있고, 원하는 목적의 어플리케이션을 개발할 수 있음
 - OpenAI, Google 등과 같은 몇몇 회사들이 LLM 모델을 API로 제공 (유료/무료)
- LLM을 직접 만들어서 개발에 이용할 수는 없을까?
- API로 제공되는 LLM을 원하는 기능을 제공하는 어플리케이션에 이용하는 대표적인 방법 - 파인튜닝, RAG

LLM 활용 방법 – 1) 파인 튜닝

■ 파인 튜닝 (Fine Tuning) – 기존의 LLM을 특정한 작업이나 상황에 맞게 조금 더 훈련(학습)시키는 방법

- 예) 많은 책과 글을 통해서, 일상적인 인간의 언어를 이해하고 답을 하는 방법을 학습한 LLM
➔ 이 모델을 의학분야에서 전문적으로 사용하고 싶다면, 의학 지식에 대한 데이터를 기존 LLM에 추가 학습시키는 것
- 이미 학습된 언어에 대한 이해와 답변 능력을 유지하면서, 필요한 분야에 대한 지식을 추가적으로 습득하여 활용




LLM 활용 방법 - 1) 파인 튜닝

■ 전이 학습 (Transfer Learning) 과 파인 튜닝

- 전이 학습


- 한 분야에서 배운 지식 (학습된 내용)을 다른 분야의 문제 해결에 전이 하여 사용하는 방법
- 새로운 학습이 필요 없으므로, 학습에 필요한 시간과 데이터 및 노력을 절감할 수 있음




LLM 활용 방법 - 1) 파인 튜닝

■ 전이 학습 (Transfer Learning) 과 파인 튜닝

- 파인 튜닝은 전이 학습의 특별한 형태



※ 추가 학습(파인튜닝)은 필요에 따라 진행



LLM 활용 방법 – 1) 파인 튜닝

■ 파인 튜닝의 실질적 어려움

- 어느 정도의 데이터로 어느 정도의 추가 학습을 해야, 기대하는 성능을 보일 수 있을지 확신할 수 없음
 - 기존 학습된 지식이 편향으로 발생할 수도 있고, 새로운 학습에 의해 기존 지식이 사라져 버릴 수도 있음
 - 이러한 문제를 고려하면서, 새로운 지식을 모델에 추가로 학습시킨다는 것은 어려운 문제
- LLM (추가) 학습을 위한 인프라 및 운용 비용
 - 거대한 파라미터와 데이터를 이용하는 LLM 모델의 학습을 위해서는 고비용의 GPU가 필수
- 데이터 준비의 어려움
 - 질문/답변 형태로 학습되고 서비스를 제공하는 LLM의 튜닝을 위해서는, 새로운 데이터 역시 질문/답변 형태로 구성해야 함
 - 이러한 데이터는, AI를 개발하는 IT(기술) 인력이 아닌, 해당 업무를 진행하는 현업의 실무 전문가들이 구성할 수 있음

■ 이러한 이유 때문에, 추가적인 학습 과정이 없는 RAG를 이용한 활용이 더 일반적

목차

- LLM 생성 과정
- LLM 생성 후 추가 고려 사항
- LLM 활용 방법
 - 파인 튜닝