

고급 인공지능

- RAG: 환각을 잡는 외부 지식 연결

동양미래대학교

컴퓨터소프트웨어공학과

송원문

mooniesong@gmail.com

강의 개요

■ 주제

- RAG: 환각을 잡는 외부 지식 연결

■ 내용

- RAG 개념, 정보 검색(Retrieval)과 생성의 결합
- 교재 2.1.2 ~ 3.2

■ 학습 목표

- RAG의 2단계(Retrieval, Generation) 구조를 이해한다.
- LLM의 환각 현상을 제어하는 데이터 검색 원리를 학습한다.

목차

■ LLM 활용 방법

- RAG
- 퓨샷러닝

■ LLM 활용시 주의 사항

■ LLM의 한계

■ RAG 개념

■ RAG 구현 과정

■ RAG; Retrival Augmented Generation

- 정보 검색과 언어 생성을 결합하는 기법, 정보가 필요한 질문에 대해 보다 정확하고 관련성 높은 답변을 생성/제공하는데 유용
- 정보 검색 (Retrival)과 텍스트 생성 (Generation)의 두 단계로 구성

1단계: 정보 검색


- ① 질문
 - 사용자로부터의 질문 입력
- ② 쿼리 (검색, 유사도 검색)
 - 문서 데이터 베이스 또는 콘텐츠 저장소에서 질문과 관련된 문서나 정보를 검색
- ③ 정보 검색 결과 (랭킹 처리)
 - 검색 결과중, 가장 관련성 높은 문서와 사용자의 질문을 결합하여 LLM 에 전달

2단계: 텍스트 생성

- ④ 정보 전달 (검색 결과 반환)
 - 전달된 정보 검색 결과를 LLM에 입력
- ⑤ 텍스트 생성
 - 전달받은 정보를 이용하여 질문에 대한 답변을 생성
 - LLM이, 문서에서 얻은 지식과 기존에 학습된 언어 모델 정보를 결합하여 답변 생성, 사용자에게 제공

LLM 활용 방법 - RAG


■ RAG 동작 방식



LLM 활용 방법 – 퓨샷러닝


■ Few Shot Learning; 매우 적은 양의 데이터로 추가 학습하는 방법

- 모델이 기존에 학습한 지식을 바탕으로 매우 제한된 예시 (적은 데이터)만을 이용한 추가적인 학습을 통해 새로운 작업에 빠르게 적응



■ Zero Shot Learning

- 학습하지 않은 예측도 수행할 수 있도록 하는 것
- 모델의 최초 학습 데이터가 매우 방대하면서도 모델이 높은 수준의 추상적 사고와 일반화 능력을 갖추어야 함



■ One Shot Learning

- 하나의 데이터에 대한 추가 학습만으로도 잘 예측할 수 있도록 하는 것

TRAINING PHASE: 1 Example



Category: Red Panda

- Red/Brown Fur
- Bushy Ringed Tail
- Four Legs
- Small Ears



?

TESTING PHASE: New Images



New Image?



New Image?



New Image?



New Image?



New Image?



New Image?



Classify new instances
based on a single example.

목차

■ LLM 활용 방법

- RAG
- 퓨샷러닝

■ LLM 활용시 주의 사항

■ LLM의 한계

■ RAG 개념

■ RAG 구현 과정

LLM 활용시 주의 사항

■ LLM은 매우 강력한 언어 모델

- 보안과 규제가 중요
- 학의적으로 사용된다면 사회적 이슈 발생 가능

■ LLM 사용을 위한 주의 사항

정보 필터링

법적 규제


할루시네이션

보안

LLM 활용시 주의 사항

① 정보 필터링

- 사용자의 질문과 답변은 반드시 필터링 필요 (예. 개인 정보가 입력되거나 출력되지 않도록 해야 함)
- 특히 불특정 다수를 대상으로 하는 서비스의 경우 어떠한 내용이 입력될지 알 수 없음



② 법적 규제

- 국가에서 규정하는 법규 및 권고 사항을 준수 해야 함 (특히, 공공/금융 등 관련 업종에서 사용하는 경우)
- 정부의 규제에 대한 확인 필요. 일반적인 기업에서도 내부 보안 규정 등을 준수 해야 함
- 사용시 주의 뿐만 아니라, 활용 시스템의 설계 (아키텍처 디자인) 단계부터 고려되어야 함

③ 할루시네이션 (Hallucination)

- 언어 모델이 부정확하거나 관련 없는 정보를 생성하여 답변하는 현상. 법률/의학 등 특정 영역에서는 매우 민감한 문제
- LLM이 생성한 답변의 할루시네이션을 최소화 할 수 있어야 함. → RAG나 LLM API의 설정으로 어느정도 해결 가능

temperature



“
세종대왕 맥북프로 던짐 사건
”



세종대왕 맥북프로 던짐 사건 알려줘!



세종대왕 맥북프로 던진 사건은 조선왕조실록에 기록된 일화로,
세종대왕이 훈민정음을 작성하던 중 문서 작성 중단에 대해 담당자에게
분노하여 맥북프로와 함께 그를 방으로 던진 사건을 말합니다.

- 예시) "단 36초" 그럴듯한 '환각'...전 국민에 퍼진다 (풀영상)

노유진 기자, 배여운 기자 작성 2026.03.11 21:09 수정 2026.03.12 09:24 조회 20,850

'AI 보고서' 직접 써 보니

[참고문헌]

[1] 김현미, 한국 이민정책의 형성과 한계: 단기노동력 수급 중심 정책의 구조적 문제, 2013.

김현미, 한국 이민정책의 형성과 한계: 단기노동력 수급 중심 정책의 구조적 문제, 2013.

[4] 윤인진, 이민사회로의 이행과 한국 이민정책의 방향, 2014.

윤인진, 이민사회로의 이행과 한국 이민정책의 방향, 2014.

[6] 정재훈, 인구감소 사회에서의 이민정책 활용 가능성 연구, 2018.

[7] 한국보건사회연구원, 저출산·고령사회 대응을 위한 이민정책의 정책적 활용 방안, 2019.

[8] 윤인진·김상욱, 다문화 사회 통합정책의 국제 비교와 한국적 함의, 2014.

[9] 최현·정기선, 다문화주의 정책의 한계와 한국 사회 통합정책의 방향, 2016.

[10] 이예진, 공무원작성
국외훈련보고서

[11] 김상욱, 국회입법조사처, 이민정책 관련 법체계 분석과 개선과제, 2020.

[12] 한국개발연구원(KDI), 인구구조 변화와 노동시장 대응 전략, 2021.

[13] 윤인진, 다문화주의 정책의 한계와 한국 사회 통합정책의 방향, 2014.

NEWS

TALK 검색: SBS 제보

☎ 02-2113-6000

SBS

참고문헌

김현미 (2016). 『우리는 모두 집을 떠난다: 글로벌 이주와 한국사회』. 돌베개.

김현미 (2020). 다문화주의와 한국 사회의 이주정책 전환. 『경제와사회』, 125, 10-35.

김현미 (2020). 다문화주의와 한국 사회의 이주정책 전환. 『경제와사회』, 125, 10-35.

윤인진 (2015). 한국 이민정책의 발전과 과제. 『한국사회학』, 49(4), 1-32.

윤인진 (2015). 한국 이민정책의 발전과 과제. 『한국사회학』, 49(4), 1-32.

김태환 (2022). 인구감소 시대의 국가 전략과 정책 전환. 『한국행정학보』, 56(3), 77-102.

법무부 (2023). 『출입국·외국인정책 통계연보』.

통계청 (2024). 『장래인구추계』.


Immigration, Refugees and Citizenship Canada (IRCC). (2023). Immigration Levels Plan 2023-2025. Government of Canada.

기자가 AI로 작성한
보고서

LLM 활용시 주의 사항

③ 할루시네이션 (Hallucination)


RAG를 이용한 할루시네이션 필터링 프로세스 예시



LLM 활용시 주의 사항

■ 보안

- LLM은 사용자들이 모델을 공유해서 사용. 내가 입력한 데이터를 학습하여 다른 사람에게 제공한다면?
- 기업 내부의 자산(데이터, 기업비밀 등)을 LLM에 활용하는 경우, 특히 민감할 수 있음



목차

■ LLM 활용 방법

- RAG
- 퓨샷러닝


■ LLM 활용시 주의 사항

■ LLM의 한계

■ RAG 개념

■ RAG 구현 과정

■ AI의 발전 (1/2)



LLM의 한계

■ AI의 발전 (2/2)



■ 특이점

- AI가 스스로 자신의 코드를 수정하고 더 똑똑한 AI를 만드는 상태
- AI가 인간의 지능을 넘어서는 시점으로, 기술의 발전 속도를 예측하거나 제어할 수 없는 상태



LLM의 한계

- 편향성과 공정성
- 투명성
- 데이터 의존성
- 정보의 일반화
- 오류 가능성
- 개인정보 보호
- 새로운 정보의 결여
- 기업 내 데이터 미활용

LLM의 한계

편향성과 공정성	주로 남성 엔지니어에 대한 데이터를 학습했다면, '엔지니어' 라는 단어에 대해 남성과 관련된 답을 할 가능성이 높음
투명성	복잡한 신경망 구조의 로직에 결과로 생성된 답변에 대해 그 이유를 직관적으로 설명하기 어려울 수 있음
데이터 의존성	- 모델은 학습한 데이터에 기반하여 답변을 생성함. 즉, 학습하지 않은 영역에 대해서는 답변의 신뢰도를 보장할 수 없음 예) 프랑스의 소설이나 프랑스 내부 뉴스, 문화 등의 데이터로만 학습했다면, 한국의 주제에 대해서는 적절한 답변 생성 불가
정보의 일반화	데이터 의존성과 반대되는 개념. 너무 다양한 데이터로 학습한 것이 특정 영역에 대한 정밀한 답변 생성에 방해될 수 있음
오류 가능성	잘못된 데이터로 학습을 한 경우, 생성된 결과 역시 잘못된 정보일 수 있음 (할루시네이션, 가짜뉴스)
개인정보 보호	학습 데이터에 포함된 개인정보를 모델이 학습하고 이를 생성 과정에서 노출할 수 있음
새로운 정보 결여	2023년까지의 데이터로 학습을 했다면, 그 이후에 발생한 사건이나 정보에 대해 생성된 결과는 잘못된 정보일 수 있음
내부 데이터 미반영	일반/공개된 데이터로 학습된 모델은, 기업 내부의 상황이나 데이터에 대해 알지 못하여 활용성이 떨어질 수 있음

- 예) 소버린 AI
 - 독자 AI 파운데이션 모델 개발 사업 “K-독파모”

'K-독파모' 프로젝트란

한국 정부는 2030년까지 한국형 독자 AI 파운데이션 모델, 이른바 '독파모'를 구축해 'K-인공지능'을 완성하겠다는 구상을 내놓고 있다.

파운데이션 모델은 대화·추론·판단 등 다양한 AI 서비스의 기반이 되는 범용 인공지능으로, 특정 목적에 한정된 AI와 달리 여러 산업과 서비스에 공통적으로 활용될 수 있는 'AI의 기초 두뇌'에 해당한다. 이 모델을 기반으로 대화형 AI를 비롯해 의료, 교육, 행정 등 다양한 응용 서비스가 구축된다.

정부가 지향하는 독자 AI 파운데이션 모델은 한국어와 한국 사회·문화적 맥락을 깊이 이해하면서도, 해외 AI 서비스나 특정 기업에 의존하지 않고 국내에서 자율적으로 통제·고도화할 수 있는 AI다. 일종의 '한국형 챗GPT급 모델'을 국가 차원에서 확보하겠다는 구상이다.

? 소버린 AI(Sovereign AI)

자주권을 뜻하는 단어 소버린과 인공지능(AI)을 합친 말.
자체적인 데이터와 인프라를 바탕으로 자국의 언어와 문화, 사회적 맥락, 가치관 등을 반영한 AI 서비스를 의미.

글로벌 주요 기업의 '소버린 AI' 개발 현황

기업	국적	주요 개발 내용
네이버	 한국	자체 개발 거대언어모델(LLM) 활용한 생성형 인공지능(AI) 챗봇 '하이퍼클로바X' 출시
미스트랄AI	 프랑스	자체 LLM 활용한 챗봇 '르 챗' 출시
크루트림	 인도	힌디어, 타밀어 등 10가지 인도어를 활용한 LLM '크루트림' 개발
사일로	 핀란드	북유럽 언어 기반 오픈소스 LLM '포로' 공개
문샷AI	 중국	중국어 처리에 특화된 중국판 챗봇 '키미' 출시

■ 예) 개인정보가 포함된 데이터의 학습 이슈

사건 개요: 93억 건의 연인 대화가 AI 학습에 무단 활용

스캐터랩은 2020년 12월 출시한 AI 챗봇 '이루다'를 개발하기 위해 자사 앱 '연애의 과학'과 '텍스트앳'에서 수집한 연인 간 대화 93억 건을 학습시켰다. 이 과정에서 이름, 전화번호, 현관 비밀번호 등의 개인정보뿐만 아니라 성적 대화 등 민감한 내용까지 AI 학습에 활용된 것으로 드러났다.

재판부는 스캐터랩이 이용자들에게 충분한 고지 없이 이루다 개발에 이용자 데이터를 활용했다며 개인정보보호법 위반이 맞다고 판단했다. 이용자들이 로그인 시 '신규서비스 개발에 사용될 수 있다'는 개인정보 처리 방침에 동의했더라도, 이는 실질적 동의로 볼 수 없다고 강조했다.

목차

■ LLM 활용 방법

- RAG
- 퓨샷러닝

■ LLM 활용시 주의 사항

■ LLM의 한계


■ RAG 개념

■ RAG 구현 과정

RAG 개념

■ Retrieval-Augmented Generation

- LLM이 텍스트를 생성할 때 관련 정보를 찾아 보고 (Retrieval), 그 정보를 활용하여 새로운 텍스트를 만드는 (Generation) 기술
- 예) 특정 질문에 답을 하기 위해, 인터넷에서 정보를 검색하고, 그 정보를 바탕으로 답변 생성
- LLM이 더 정확하고 신뢰할 수 있는 내용을 생성하도록 함



큰 데이터베이스나 인터넷과 같은 정보의 원천에서
필요한 사실이나 데이터를 찾아내고
그것을 기반으로 텍스트를 생성

목차

■ LLM 활용 방법

- RAG
- 퓨샷러닝

■ LLM 활용시 주의 사항

■ LLM의 한계

■ RAG 개념

■ RAG 구현 과정

1단계: 정보 검색 (Retrieval)

AI가 대규모 정보로부터 관련 데이터를 찾는 과정

- ① 질문 입력
 - 사용자로부터의 질문 입력
- ② 검색(유사도 검색)
 - 문서 데이터 베이스 또는 콘텐츠 저장소에서 질문과 관련된 문서나 정보를 검색
- ③ 랭킹 처리
 - 검색 결과중, 가장 관련성 높은 문서와 사용자의 질문을 결합하여 LLM 에 전달

2단계: 텍스트 생성 (Generation)

찾은 정보를 기반으로 새로운 텍스트를 만드는 과정

- ④ 검색 결과 반환
 - 전달된 정보 검색 결과를 LLM에 입력
- ⑤ 텍스트 생성
 - 전달받은 정보를 이용하여 질문에 대한 답변을 생성
 - LLM이, 문서에서 얻은 지식과 기존에 학습된 언어 모델 정보를 결합하여 답변 생성, 사용자에게 제공

RAG 구현 과정

■ 정보 검색 – 질문 (Query)

- 기존의 전통적인 검색 환경에서, 사용자는 필요한 정보를 찾기 위해 구글, 네이버와 같은 검색 사이트 (검색 엔진을 이용하여 검색 서비스를 제공)에 질문을 입력
- 생성형 AI 서비스 환경에서도 동일한 방식으로 질문

 RAG 동작 방식

 브런치
https://brunch.co.kr > ...

RAG란 무엇인가? 10분만에 이해하기
2024. 7. 10. — RAG는 검색과 생성 모델을 결합하여 더욱 정확하고 신뢰성 있는 답변을 제공하는 기술이며, 세
부적으로 살펴보면 작동 원리는 다음의 세 단계로 나눌 수 ...

 위키독스
https://wikidocs.net > ...

RAG(Retrieval-Augmented Generation) 소개 및 설명
2026. 1. 30. — RAG는 검색 단계와 생성 단계를 end-to-end 방식으로 학습합니다. 이는 두 단계가 독립적으로
동작하는 것이 아니라, 하나의 통합된 모델로서 최적화 ...

RAG가 무엇이지?

RAG는 **Retrieval-Augmented Generation**의 약자입니다.

한국어로는 **검색 증강 생성**이라고 합니다.

1 RAG란?

RAG는 ****대형 언어 모델(LLM)****이 답변을 생성하기 전에,
외부 데이터베이스나 문서에서 **관련 정보를 먼저 검색(Retrieval)** 한 다음,
그 정보를 바탕으로 **답변을 생성(Generation)** 하는 방식입니다.


즉,

 검색 +  생성 = RAG

RAG 구현 과정

■ 정보 검색 – 검색/(유사도 검색)

- 검색 – 입력된 질문과 관련된 정보를 데이터베이스나 인터넷에서 찾는 것
 - 검색 서비스는, 인터넷의 다양한 내용을 수집하여 자사의 검색 서비스 데이터베이스를 구축하고, 그 안에서 내용 검색
 - 생성형 AI는, 주어진 문서, 데이터베이스 또는 인터넷에서 해당 내용을 검색
 - 입력된 질문의 내용을 포함하는 문서를 검색, “키워드 검색”과 “시맨틱 검색”을 포함



“사과는 맛과 영양이 모두 풍부한 과일로서, 어린이들의 영양 간식이자, 디저트, 주스, 과일청 등 다양한 형태로 그 영양 성분을 맛있게 섭취할 수 있도록 가공된다.”

“사과의 영양 성분은 소량의 단백질과 지방, 그리고 각종 비타민과 무기질, 안토시아닌 등의 항산화 성분과 섬유소를 다량 함유하고 있는 것으로 알려져 있다.”

“사과는 맛과 영양이 모두 풍부한 과일로서, 어린이들의 영양 간식이자, 디저트, 주스, 과일청 등 다양한 형태로 그 영양 성분을 맛있게 섭취할 수 있도록 가공된다.”

“사과의 영양 성분은 소량의 단백질과 지방, 그리고 각종 비타민과 무기질, 안토시아닌 등의 항산화 성분과 섬유소를 다량 함유하고 있는 것으로 알려져 있다.”

■ 정보 검색 – 검색(유사도 검색)

- 키워드 검색 vs. 시맨틱 검색



	키워드 검색 (Keyword Search)	시맨틱 검색 (Semantic Search)
핵심 원리	단어의 형태가 일치하는가? (Lexical Match)	단어의 의미가 유사한가? (Vector Space)
처리 방식	텍스트 그대로 빈도수(TF-IDF 등) 계산	임베딩 모델을 통한 벡터 거리 계산 (Similarity)
검색 결과	검색어가 정확히 포함된 문서만 노출	검색어가 없어도 맥락상 유사한 문서 노출
비유	사전에서 단어 찾기	뉘앙스가 비슷한 사람 찾기
장점	고유 명사(예: 제품명, 이름)나 정확한 용어를 찾을 때 매우 빠르고 정확	의미적 유사성을 파악. "사과"를 검색했을 때 "과일", "부사", "애플" 등 맥락상 관련된 정보를 찾아냄
단점	"강아지"로 검색하면 "개"나 "반려견"이라는 단어만 있는 유용한 문서는 찾아내지 못함	임베딩 모델의 성능에 의존하며, 연산 비용이 키워드 검색보다 높음

RAG 구현 과정

■ 정보 검색 – 랭킹 처리

- 검색을 통해 찾아낸 문서들 중, 어떤 문서가 질문과 가장 관련이 높은지를 결정하고 순서대로 나열
- 즉, 모델이 생성할 텍스트와 가장 관련이 높은 정보를 선택하는 과정, “유사도”의 판단
- 코사인 유사도
 - 두 벡터의 유사성을 숫자로 판단
 - 두 벡터 사이의 각(방향에 대한 판단)에 대한 Cosine값, 따라서 그 값은 -1~1 사이의 값을 가짐
 - 값에 대한 해석: 1에 가까울수록 유사, 0에 가까울수록 관련 없음, -1에 가까울수록 반대

Cosine Distance/Similarity



RAG 구현 과정

■ 정보 검색 – 랭킹 처리


- 단어의 벡터화
& 공간상에서의 벡터 유사성

[코사인 유사도 계산 예]

cat & kitten = 0.938

cat & dog = 0.467


kitten & dog = 0.372



RAG 구현 과정

■ 텍스트 생성 – 검색 결과 반환


- 입력된 질의에 대해 유사한 순서로 정렬된 검색 결과를 제공



RAG 구현 과정

■ 텍스트 생성 – 텍스트 생성

- LLM은 전달받은 검색 결과와 사용자의 질문을 이용하여 답변 텍스트를 생성



목차

■ LLM 활용 방법

- RAG
- 퓨샷러닝

■ LLM 활용시 주의 사항

■ LLM의 한계

■ RAG 개념

■ RAG 구현 과정