



인공지능과 인간의 대화

7. 인공지능은 과연 인간보다 공정할까?



7주차

인공지능은 과연 인간보다 공정할까?



저를 비롯한 인공지능은 주어진 데이터와 알고리즘을 이용해 학습하고 또다른 정보를 만들어 냅니다. 하지만 인공지능이 만들어낸 정보가, 편향된 결과로 사회적 물의를 일으키기도 했습니다.

마이크로소프트 사의 챗봇은 비속어와 인종, 성차별 발언을 쏟아내 운영을 중단하기도 했고, 남성 지원자가 다수였던 과거의 이력서 데이터를 학습한 시가 여성 지원자를 차별하는 결과가 나타났던 아마존의 AI 시스템은 폐기되었습니다.

우리나라의 챗봇 '이루다' 역시 성차별, 인종차별 등 사회적 혐오를 부추긴다는 우려가 있었고, 이용자들의 성희롱 문제와 함께 제작 과정에서 개인정보가 유출됐다는 의혹 등 수많은 논쟁거리를 불러일으켰습니다.

인공지능은 가치중립적이기 때문에 사람보다 공정할 것이라는 기대를 합니다.

과연 인공지능이 사람보다 공정할까요?

07

학습목표

- 인공지능의 편향과 차별의 문제를 인식할 수 있다.
- 인간의 편향성을 극복하기 위한 계몽과 그 역설을 이해할 수 있다.
- 공정성을 위한 투명성과 다양성 존중의 가치를 서술할 수 있다.

07

학습내용

- 인공지능의 편향과 차별
- 인간 계몽의 역설
- 투명성과 다양성 존중

1차시. 인공지능의 편향과 차별

1

차별 강화와 불공정성

- 인공지능의 판단이나 의사결정으로 인해 얻어진 결과가 사회가 원하지 않는 종류의 편향과 차별을 띠 수 있다. → 인공지능의 '차별 강화' 혹은 '불공정성'의 문제
- 기계학습(machine learning)을 하는 인공지능에게 주어지는 데이터나 설계된 알고리즘에 편향(성차별, 인종차별 등)이 내재 되어 있을 경우 해당 인공지능이 결과적으로 유사한 편향을 띠게 된다.
- 데이터 과학자 캐시 오닐(Kathy O'Neil)의 책 <대량살상수학무기(Weapons of Math Destruction)>에서 알고리즘이 만들어질 때 개발자가 가진 여러 편향된 가정(assumption)이 포함되기에 알고리즘은 결코 중립적이지 않다고 주장한다.

예: 신용평가 알고리즘

고객이 대출을 갚지 않은 횟수가 몇 차례가 되어야 신용불량자로 분류할 것인가는 개발자가 직접 결정하는 사안이므로 이는 중립적이기 어렵다고 본다.


- 빅데이터 및 인공지능 알고리즘은 사회에 존재하는 차별을 증폭하고 영속화할 수 있다.
→ 차별에 젖어 있는 사회에서 얻어진 데이터가 인공지능의 알고리즘에 투입될 경우, 차별을 담은 결과를 만들어 내기 때문
- 인공지능의 차별 강화와 불공정성의 문제를 제대로 인식하고 적극적인 대처가 필요하다. 특히 소수나 특정 계층이 아닌 다수의 구성원이 그것을 공유할 수 있어야 한다는 점(이익 공유)을 고려한다면 적극적인 대처의 필요성은 더욱 커진다.

2

불투명성과 설명불가능성

- 인공지능 알고리즘이 구체적으로 어떠한 인과적 메커니즘에 의해 출력값을 산출하는지 알 수 없다.
→ 인공지능 알고리즘을 ‘블랙박스’에 비유하기도 한다.
- 심화학습(deep learning)에 기반한 인공지능의 경우, 수많은 레이어(layer)를 이루는 개개의 노드(node) 간에 부여된 웨이트(weight) 값이 얼마인지 개발자조차도 알기 어렵다.
→ 인공지능에 의한 판단, 의사결정에 대한 정확한 이해나 설명이 불가능
- 인공지능 알고리즘에 의한 의사결정도 가능한 한 투명해야 하며, 이와 관련하여 해당 주체에게 책무성이 요구된다. 책무성을 귀속시킬 수 있는 대상은 인공지능의 설계자나 제조자일 수도 있고, 인공지능 자체일 수도 있다.
- 인공지능 알고리즘의 불투명성의 원인의 제도적 차원과 현실적 차원
 - 제도적 차원: 인공지능의 알고리즘 소스 코드(source code)가 영업 비밀이나 지적재산권 제도를 통해 법적으로 보호 받고 있을 가능성이 높아, 법원 등 외부 주체가 공개를 강제하기 어렵다.
 - 현실적 차원: 인공지능 알고리즘에 대한 조사와 검증에는 막대한 시간과 비용이 들어 검증을 제도적으로 현실화하기 어렵다.

[출처: 김건우, 2019: 111~119]



Q. 인간의 생명, 안전과 직결된 의사결정을 하는 인공지능의 작동원리를 설명할 수 없다면 어떤 문제가 발생할까요? 여러분의 생각을 정리해 보세요.

2차시. 인간 계몽의 역설

1

인간의 편향에 맞선 계몽

- 계몽: 17-18세기에 인간의 지성 혹은 이성을 '빛'에 비유하면서 그 빛을 통해 당시의 사람들이 빠져 있던 편견, 선입견, 미성숙 등으로부터 벗어나게 하려던 철학적 운동

| 베이컨의 계몽주의

- 인간의 정신을 사로잡고 있는 이상
 - ① 종족 이상: 인간이라는 종족 자체에 뿌리박고 있는 이상 → 인간의 시점에서 마음대로 판단
 - ② 동굴 이상: 각 개인이 가진 이상 → 우물 안의 개구리처럼 좁은 시야로 보는 것
 - ③ 시장 이상: 인간 상호 간의 교류에서 생기는 이상, 언어적 부정확성에서 야기 되는 이상
 - ④ 극장 이상: 다양한 학설과 그릇된 증명 방법으로 인해 생기는 이상, 권위와 역사에 기대는 이상
- 네 가지의 이상은 네 가지의 편향으로 간주됨
 - ① 종족 편향: 생물학적 특징으로 인한 편향
 - ② 동굴 편향: 개인별 특질로 인한 편향
 - ③ 시장 편향: 사회화 과정에서 소속 집단의 특징으로 인한 편향
 - ④ 극장 편향: 사회화 과정에서 권위자나 대중매체의 영향으로 형성된 편향
- 참된 귀납은 감각과 개별자에서 출발하여, 지속적 · 점진적으로 상승한 다음, 가장 보편적인 명제까지 도달하는 방법
- 답러닝
 - 의지와 감정 없이 수행
 - 베이컨이 꿈꾸었던 '마른 빛'의 완결판

1

인간의 편향에 맞선 계몽

| 칸트의 계몽주의

- 17~18세기 경험론 철학의 전통에서 도덕은 여전히 그 근거를 감정에 두고 있고, 공감(sympathy)은 사람들이 함께 사는 도덕생활의 기초가 된다. 하지만 칸트는 도덕 형이상학의 정초를 위해 외부의 영향을 받기 쉽고 개별적인 성격을 갖는 도덕 감정을 배제해야 한다고 말한다.
- 자기행복, 도덕 감정 등 타율성을 초래할 수 있는 경험적 원리를 거부하고 자율성, 보편성, 실천적 필연성을 담보하는 '순수한 실천이성'의 선택 의지로부터 도덕법칙 정초
→ 의지와 감정은 이성에 의해 통제된다.

| 인간의 편향에 맞선 계몽주의

- 인간의 편향과 관련해 계몽을 정의해보자면, 계몽은 인간의 편향을 완화하기 위해 개별 신체의 일시적 상태로부터 비롯하거나 개인의 제한된 사회적 관계나 경험으로부터 비롯하는 감정, 욕망, 의지 등을 억제하는 것, 보편화 능력을 갖는 지성 혹은 순수 이성을 발전시켜 거기에 감정, 욕망, 의지 등을 종속시키는 것이다.

2

계몽의 역설

- 인간은 개별적 감정, 욕망, 의지로부터 벗어날 수 없다. 그래서 계몽의 시대는 이성을 강조하긴 했으나 동시에 연애의 시대이자 예술의 시대이기도 했다.
- 19세기로 넘어갈 무렵, 개별성, 특수성, 감정, 환상 등을 강조하는 낭만주의가 계몽에 도전한다.
→ 근대인은 공적영역에서는 계몽주의자, 사적영역에서는 낭만주의자였다.
- 칸트는 보편성의 기준, 즉 계몽을 위해 반드시 자유로울 필요가 있는 이성의 공적 사용범위를 "세계 시민 사회"로 설정했지만 현실의 인간들에게 보편화의 한계는 조직, 지역사회, 민족 등이었다.
→ 제한된 보편성에 만족하는 이성은 특수한 목적을 위한 '도구적 이성'에 머물게 됨
- 1944년, 호르크하이머와 아도르노의 <계몽의 변증법>
 - 인류가 왜 '새로운 야만 상태'에 빠졌는가?
 - 왜 계몽의 자기 파괴에 이르렀는가?

[출처: 베이컨 2011: 43, 55 / Kant(1977), 55-56 / 정성훈, 2021: 214-218]

2

계몽의 역할

- 냉장고, 비행기, 통신기구 등이 모두 발명되었고 보편적 공교육을 통해 누구나 스스로의 지성을 사용할 수 있게 된 20세기 초반, 인류는 두 번의 세계 대전을 겪게 되고 계몽의 성과는 인류에 대한 범죄에 사용된다. (예: 핵 무기, 나치)
→ 도구적 이성만 결국 인간을 효과적으로 죽이는데 사용

- 인공지능(AI) VS. 아돌프 아이히만(Adolf Eichmann)

[아돌프 아이히만]

- 도덕 감정과 공감능력을 거의 상실한 사람
- 민족으로 제한된 보편성에 따라 자율적으로 도덕법칙의 명령에 따른 사람
- 마른 빛에 가까운 도구적 이성으로 자신에게 주어진 직무를 수행한 사람
→ 자신의 의지와 감정을 이성의 아래에 두어 철저히 통제하는 데에 뛰어난 사람
- 한나 아렌트의 평가
: 어느 것도 타인의 관점에서 바라볼 수 있는 능력이 없고, 공직에서 사용하는 용어의 상투어가 아니면 단 한 구절도 말할 능력이 없는 사람

인공지능	아돌프 아이히만
어떠한 예외 상황도 발생할 수 없음	[예외 상황] • 유대인인 자신의 조카를 도와준 것 • 삼촌의 개입에 따라 유대인 부부를 도와준 것
[인공지능] • 인간보다 더 뛰어난 보편화 능력을 갖춤 • 목표 변수 설정에 따라 특정한 방향으로 제한되어 처리됨 → 제작자의 편향된 의도가 개입되면 문제가 심각해질 수 있음	
인공지능	인간
방대한 양의 데이터를 스스로 발굴하지만, 비판적으로 성찰하지 못함 → 더 큰 힘을 가진 아이히만이 탄생할 수 있어 더욱 주의 필요	전혀 접해보지 못한 경험도 간접적으로 경험 → 반성의 계기를 가지게 되고, 또 다른 방향성 제시

[출처: 아렌트(2006), 104-105/정성훈, 2021: 216-218]

3차시. 투명성과 다양성 존중

1

알고리즘의 투명성

- 알고리즘의 불투명성은 인간 행위자가 알고리즘 내부의 편향성과 그 원인을 추적하고 이를 제거하거나 방지하기 어렵게 한다. 그러므로 알고리즘의 투명성이 보장되어야 한다.
→ 개발 측의 입장에서는 재산권과 직결되는 문제일 수 있지만 알고리즘의 투명성 요구는 모든 정보를 공개할 것을 요구하는 것이 아니다.

[EU의 개인정보 보호 규정(GDPR)]

- 알고리즘의 투명성 문제를 '설명을 요구할 권리'로 대응
- 개인 주체의 프라이버시 보호
- 정보 주체가 자신의 정보 처리 절차를 알 수 있게 쉬운 방식으로 전달

[아실로마시 준칙]

- 실패의 투명성(Failure Transparency): 인공지능이 해를 입힐 경우, 원인을 확인할 수 있어야 함
- 사법적 투명성(Judicial Transparency): 자동화된 시스템의 사법적 결정 참여에 대해 인간으로 구성된 감사 기관의 만족스러운 설명이 제공되어야 함
- 프라이버시: 인공지능과 마찬가지로, 인간들도 자신이 생성한 데이터를 접근, 관리 및 제어할 수 있는 권리가 있어야 함

[미 백악관 보고서]

- 최소한의 투명성
- 관계자의 해명가능성
- 법의 절차적 정당성 고려하고 증진
- 알고리즘 설계 및 산출된 결과물에 대한 지속적 검사

[출처: 허유선, 2018: 191-201]

2

책임 있는 알고리즘 설계

- 윤리적 설계
: 알고리즘의 편향성, 그로 인한 인공지능의 차별적 작동 및 기존 차별의 확산과 강화를 막기 위해서는 개발 초기, 설계 단계부터 차별 문제를 민감하게 고려하며 이를 지양하는 책임 있는 설계가 요구된다. → 인간이 주체가 되어야 함
- 윤리적 설계의 방향성
 - 아실로마시 준칙: 고도로 자율적인 인공지능이 '인간의 가치와 합치'하도록 설계 되어야 한다 고 선언 → 인간의 존엄성, 권리, 자유 및 문화 다양성과 양립될 수 있도록 설계
 - EU의 알고리즘 규제: 의사 결정을 알고리즘에게 전부 위임하지 않도록 해야 함
 - 미 백악관 보고서
 - 인간 판단이 빅데이터와 알고리즘에 지나치게 의존하지 않아야 함을 강조
 - 동등 기회 설계(Equal Opportunity by Design) 원리 강조
→ 무비판적으로 편향성을 회피하고 경감시키기 위해 주의를 기울이는 것이며, 기회의 평 등, 공정성 등 '민주주의 원리'를 강화하는 것에 기여한 설계
- 책임 있는 알고리즘의 설계
 - 설계자 및 개발자: 인공지능 시스템의 사용, 오용, 활용과 관련한 도덕적 함의의 이해관계자들로서 이를 만들어 나갈 책임
 - 역사적 편향은 없는가?
 - 집단의 특징이 들어가지 않았는가?
 - 자본의 이해관계에 의한 편견이 들어가지는 않았는가?
 - 외적, 사회적 압력은 작용하지 않았는가?
 - 사용자: 알고리즘의 학습은 사용자의 피드백 혹은 상호작용에 의해 향상되고 강화되므로 사용자 본인이 기본적으로 알고리즘의 학습에 영향을 미칠 수 있음을 알고 있어야 함
 - 새로운 기술의 문해력을 높이고 기술에 의한 차별 문제의 성격을 인지, 이해
→ 인공지능의 객관성에 대한 과도한 환상 및 의존을 경계
 - 기업에게 윤리적 알고리즘 설계와 운영 요구, 외부자의 관점에서 기업의 시스템 감시
 - 정부: 연구 및 산업 개발을 지원, 독려하며 인공지능에 의한 차별 문제에 정책적으로 대응

[출처: 허유선, 2018:191-201]

3

다양성 존중과 포용성

- 다양성: 능력, 나이, 민족성, 성별, 인종, 성적 지향, 종교 등을 포함하여 개인의 독특함을 나타내는 차이
- 포용성: 다양성을 존중하고 차이를 활용하면서 누구도 배제하지 않는 공동체를 만드는 것
- 다양성을 존중하는 포용적 인공지능은 알고리즘을 투명하게 개발할 능력과 데이터를 컨트롤할 힘이 전반적으로 분산되어 균형을 이룬다는 개념을 바탕으로 한다.
- 인공지능이 포용성 있는 데이터를 습득하기 위해서는 포용성 있는 지식, 데이터를 포괄적으로 학습할 수 있는 설계 프로세스나 알고리즘이 선행되어야 한다.
→ 기술은 인간의 편견을 해결하는 직접적 수단으로서 다양성과 포용성을 추구할 수 있다.

[출처: 김성애 외, 2022: 217-219]

1. 인공지능의 편향과 차별

- 차별 강화와 불공정성으로 차별을 반영하는 데에 그치지 않고 그것을 증폭하고 영속화 할 위험이 있음
- 불투명성과 설명불가능한 특성으로 블랙박스 불리며, 이에 대한 책무성과 투명성이 요구됨

2. 계몽의 역설

- 인간의 편향성 개선을 위해 인간의 이성을 추구함: 베이컨과 칸트의 계몽
- 세계대전 등으로 도구적 이성으로 전락함

3. 투명성과 다양성 존중

- 최소한의 통제력과 개입가능성을 전제함
- 책임 있는 알고리즘을 고려한 윤리적 설계를 해야 함
- 다양성 존중과 포용성이 필요함

- 김건우(2019). 차별에서 공정성으로. 法學研究, 61.
- 김성애 외(2022). 모두를 위한 인공지능과 윤리. 삼양미디어.
- 정성호(2021). 인공지능의 편향과 계몽의 역설에 대한 반성적 접근. 철학연구, 132.
- 허유선(2018) 인공지능에 의한 차별과 그 책임 논의를 위한 예비적 고찰. 한국여성철학, 29.
- 베이컨, 프랜시스(2011). 신기관. 한길사
- 아렌트, 한나(2006). 예루살렘의 아이히만. 한길사
- 칸트, 임마누엘(2019). 도덕형이상학정초, 실천이성비판. 한길사